

Mineração de Dados Educacionais Aplicada à Educação e Apoio Pedagógico

Mateo Zanette¹, Mateus Mendes Cabral^{1,2}, Thiago Felipe Garcia^{1,3}

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

²Programa de graduação em Sistemas de Informação – Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10417980,10417820 10414699}@mackenzista.com.br

Resumo. *A crescente disponibilidade de dados educacionais apresenta uma série de oportunidades para a análise e compreensão de fatores que influenciam o desempenho dos estudantes. Comumente, parte dessas informações ainda não são utilizadas em análises sistemáticas ou integrada a processos de tomada de decisão pedagógica e administrativa pelas instituições de ensino. Este projeto busca investigar como técnicas de Mineração de Dados Educacionais (Educational Data Mining - EDM) podem ser aplicadas para identificar padrões em registros acadêmicos, administrativos e comportamentais. Serão explorados métodos estatísticos, algoritmos de aprendizado de máquina, técnicas de regras de associação e algoritmo Apriori, para identificar relações entre as variáveis estudadas. Utiliza-se uma base de dados sintética referente a estudantes do ensino médio para fins de experimentação, possibilitando a análise do comportamento das técnicas selecionadas. Os resultados buscam atuar como um recurso de apoio para a criação e aplicação de estratégias pedagógicas baseadas em dados, contribuindo para a identificação precoce de riscos acadêmicos e para o desenvolvimento de intervenções alinhadas às necessidades observadas.*

Palavras-chave: *Mineração de Dados Educacionais; Aprendizado de Máquina; Regras de Associação; Algoritmo Apriori; Predição Acadêmica; Apoio Pedagógico.*

1. Introdução

As instituições de ensino têm aumentado a frequência com que novos dados relacionados ao desempenho acadêmico, frequência, atividades extracurriculares, informações administrativas e outros aspectos da trajetória estudantil têm sido produzidos e armazenados. A literatura demonstra que esses registros, embora vastos, nem sempre são analisados de forma sistemática, o que limita a compreensão de fatores associados ao rendimento escolar e à identificação precoce de situações que demandam intervenção

pedagógica (Khan et al., 2023; Maniyan, Ghousi & Haeri, 2024; Chen et al., 2025). Pesquisas recentes mostram que o uso estruturado de dados educacionais pode apoiar instituições na identificação de padrões de comportamento, predição de desempenho e compreensão de fatores que influenciam a aprendizagem (Safour, Essgaer & Alshareef, 2024; Alghamdi, 2023).

A área de Educational Data Mining (EDM) apresenta métodos capazes de transformar tais registros em conhecimento, permitindo explorar relações entre variáveis, identificar padrões recorrentes e apoiar decisões baseadas em dados. Entre essas técnicas, destacam-se as regras de associação, algoritmos de aprendizagem de máquina, análise de clusters e métodos estatísticos, amplamente aplicados na literatura para modelar comportamentos acadêmicos e analisar fatores relacionados ao desempenho estudantil (Feng, Fan & Ao, 2022; Brezack et al., 2025; Li, 2025).

O problema de pesquisa investigado neste trabalho consiste em compreender como técnicas de mineração de dados podem ser usadas para identificar padrões ocultos em dados escolares e apoiar estratégias de acompanhamento pedagógico. Observa-se, na literatura e na prática institucional, uma lacuna referente ao uso sistemático de métodos de EDM em contextos educacionais que utilizam bases sintéticas ou anonimizadas para experimentação, o que pode limitar a avaliação de modelos antes de sua adoção em ambientes reais (Attiya & Shams, 2023; Wang, 2024).

O objetivo geral desta pesquisa é investigar a aplicação de técnicas de EDM para identificar relações e padrões em uma base de dados sintética referente ao ensino médio. Para alcançar esse objetivo, são definidos os seguintes objetivos específicos: realizar a análise exploratória da base de dados; aplicar técnicas de pré-processamento adequadas ao contexto educacional; aplicar algoritmos de regras de associação; interpretar os padrões identificados e avaliar sua relevância para o contexto escolar; e discutir o potencial de aplicação dos resultados em cenários institucionais. A relevância desta pesquisa reside na possibilidade de demonstrar o uso estruturado de técnicas de EDM em um ambiente controlado e seguro, utilizando dados sintéticos que permitem testar abordagens antes de sua aplicação em instituições de ensino. Além disso, o estudo contribui para fortalecer práticas de análise baseadas em dados, auxiliando na identificação de fatores que podem influenciar o desempenho estudantil e fundamentar intervenções pedagógicas (Bhagya & Sripriya, 2022; Lam et al., 2024; Rahman et al., 2022).

A opção metodológica adotada neste projeto consiste na aplicação de técnicas de Mineração de Dados Educacionais com foco na descoberta de padrões por meio de regras de associação, utilizando o algoritmo Apriori como principal abordagem analítica. A escolha dessa técnica se justifica pela sua capacidade de identificar relações frequentes entre variáveis categóricas, permitindo a extração de padrões interpretáveis e potencialmente úteis no contexto educacional.

Além disso, o projeto adota uma abordagem complementar com técnicas de aprendizado de máquina supervisionado, visando ampliar a análise dos dados e possibilitar a identificação de tendências relacionadas ao desempenho acadêmico. A utilização de uma base de dados sintética permite um ambiente controlado para experimentação, garantindo segurança no uso dos dados e flexibilidade na validação das técnicas aplicadas.

Dessa forma, a opção do projeto combina análise exploratória, mineração de padrões e modelagem preditiva, com foco na geração de conhecimento aplicável ao contexto pedagógico.

2. Referencial Teórico

Diversos estudos têm destacado o potencial da EDM na identificação de padrões relacionados ao desempenho e à permanência estudantil. Attiya e Shams (2023) apontam que modelos preditivos têm sido amplamente utilizados para investigar fatores associados à evasão e retenção, permitindo que instituições atuem de forma preventiva. A revisão conduzida pelos autores evidencia que a combinação de dados demográficos, acadêmicos e comportamentais amplia a capacidade explicativa dos modelos, ressaltando a relevância de bases multidimensionais. De forma complementar, Bhagya e Sripriya (2022) discorrem sobre desafios associados ao uso de dados em ambiente educacional, destacando questões de heterogeneidade, qualidade dos registros e necessidade de métodos capazes de lidar com múltiplos tipos de variáveis.

Com a expansão das técnicas de aprendizado de máquina no campo educacional, estudos recentes têm explorado métodos de classificação, regressão e modelos *ensemble* para previsão de rendimento e desempenho. Alavala et al. (2025) demonstram que abordagens baseadas em *ensembles* tendem a obter resultados superiores quando comparadas a algoritmos isolados, especialmente em tarefas de predição de desempenho acadêmico. Esses avanços reforçam o papel da EDM na construção de indicadores que auxiliam práticas pedagógicas baseadas em evidências.

Além dos aspectos puramente preditivos, a literatura também aborda o uso de sistemas de apoio à decisão educacional. Wang (2024) propõe um framework que combina análise de *big data*, aprendizado de máquina e teoria de redes complexas, evidenciando a ampliação do escopo das aplicações analíticas no contexto educacional. Esses sistemas buscam integrar múltiplas fontes de dados e gerar informações que auxiliem gestores e docentes na compreensão de comportamentos e tendências coletivas.

Outro eixo relevante no campo da EDM envolve a extração de relações entre variáveis utilizando técnicas como regras de associação. Li (2025) apresenta melhorias no algoritmo Apriori e demonstra sua aplicabilidade em sistemas de apoio à decisão educacional, apontando que a mineração de padrões frequentes pode revelar relações não evidenciadas por análises tradicionais. Essas contribuições reforçam a importância de se investigar dependências e correlações entre aspectos acadêmicos e comportamentais dos estudantes.

Com o avanço da educação digital, torna-se crescente o uso de dados de interação online como insumo para modelos preditivos. Alghamdi (2023) mostra que registros de comportamento em *Sistemas de Gestão da Aprendizagem (Learning Management Systems - LMS)*, como tempo de acesso, navegação e participação, podem contribuir para a modelagem de desempenho acadêmico, sugerindo novas oportunidades de análise para bases educacionais que incorporam indicadores de engajamento. De forma semelhante, Lam et al. (2024) explora a modelagem de avaliação preditiva, destacando como estimativas antecipadas de desempenho podem apoiar práticas avaliativas e intervenções pedagógicas.

Estudos focados em análises específicas também demonstram a diversidade das aplicações da EDM. Rahman et al. (2022), por exemplo, investigam dados de resolução de problemas em programação para identificar padrões de aprendizado, evidenciando como abordagens analíticas podem apoiar o desenvolvimento de competências em áreas de alta complexidade cognitiva.

Diante do contexto apresentado, observa-se que a literatura aponta para três eixos principais de investigação: (i) predição de desempenho e permanência; (ii) mineração de padrões para identificação de relações entre variáveis; e (iii) uso de sistemas analíticos para apoio à tomada de decisão. Esses eixos fundamentam a pesquisa desenvolvida, que se propõe a explorar padrões e tendências em dados educacionais por meio de técnicas de mineração e aprendizado de máquina aplicadas a uma base sintética. A utilização desse tipo de base acompanha recomendações presentes na literatura recente, especialmente em relação à segurança, anonimização e flexibilidade experimental para validação de métodos analíticos.

3. Descrição do Problema

As instituições de ensino produzem grandes volumes de dados acadêmicos, demográficos, sociais e comportamentais sobre seus estudantes frequentemente. Apesar dessa abundância de informações, esses dados raramente são explorados de forma sistemática para apoiar a compreensão de fatores que influenciam o desempenho escolar, e propor ações pedagógicas que combatam esses fatores.

O problema central abordado neste trabalho consiste em investigar como técnicas de Inteligência Artificial, mais especificamente algoritmos de mineração de regras de associação, podem ser aplicadas para identificar padrões relevantes entre características socioeconômicas, comportamentais e indicadores de desempenho estudantil em uma base de dados educacional sintética de grande escala.

Busca-se compreender como diferentes algoritmos como o Apriori, Eclat e FP-Growth se comportam diante do mesmo conjunto de dados, avaliando sua capacidade de extrair regras significativas, a quantidade de padrões gerados e a sensibilidade aos parâmetros adotados.

4. Metodologia

A pesquisa caracteriza-se como exploratória, descritiva e aplicada. Ela é exploratória ao investigar relações e padrões presentes na base de dados sem hipóteses previamente consolidadas, alinhando-se à abordagem recomendada por autores como Feng, Fan e Ao (2022) e Safour, Essgaer e Alshareef (2024), que destacam a importância da exploração inicial de padrões ocultos em dados educacionais. É também descritiva, pois analisa variáveis acadêmicas, demográficas e comportamentais por meio de estatísticas e visualizações, conforme práticas apresentadas por Zhou et al. (2021) e Rahman et al. (2022) em estudos que utilizam análises descritivas para caracterizar o comportamento estudantil. Por fim, assume natureza aplicada ao empregar técnicas de mineração de dados para gerar conhecimento com potencial de apoiar intervenções

pedagógicas em contextos reais, conforme discutido em Maniyan, Ghousi e Haeri (2024) e Chen et al. (2025).

O desenvolvimento da investigação inicia-se com o levantamento bibliográfico, contemplando estudos sobre Mineração de Dados Educacionais, Regras de Associação, Aprendizado de Máquina e exemplos de aplicações do algoritmo Apriori em ambientes educacionais. A literatura consultada, incluindo autores como Attiya e Shams (2023), Bhagya e Sripriya (2022), Wang (2024) e Li (2025), fornece o embasamento teórico necessário para compreender o estado da arte e orientar as etapas analíticas.

Em seguida, procede-se à seleção e compreensão da base de dados sintética utilizada no estudo. A escolha da base contendo atributos acadêmicos, demográficos e comportamentais de estudantes do ensino médio, se baseia em princípios de ética e segurança, permitindo que a experimentação ocorra sem riscos associados ao uso de dados sensíveis. Após a familiarização com os dados, realiza-se uma *Análise Exploratória de Dados (Exploratory Data Analysis - EDA)*, composta por procedimentos como cálculos estatísticos, tratamento de valores ausentes, verificação de correlações, identificação de variáveis categóricas e numéricas e produção de visualizações gráficas, entre outros passos.

Concluída essa análise, inicia-se o pré-processamento dos dados, etapa em que são aplicadas técnicas como normalização ou padronização de variáveis numéricas, codificação de variáveis categóricas, balanceamento de classes por meio de algoritmos do pacote quando necessário, e divisão da base em conjuntos de treinamento e teste. Essas operações asseguram que os algoritmos possam operar adequadamente e reduzam vulnerabilidades analíticas, como vieses decorrentes de desbalanceamentos.

Com a base devidamente preparada, avançam-se para as fases de descoberta de regras de associação e modelagem preditiva. A extração de padrões identificará conjuntos frequentes e irá gerar regras de associação avaliadas por métricas como suporte, confiança e *lift*, conforme descrito por Agrawal e Srikant (1994) e aprimorado por Li (2025). Complementarmente, a modelagem preditiva envolve o treinamento de algoritmos supervisionados, os quais serão avaliados a partir de métricas como acurácia, precisão, recall, F1-score e matriz de confusão, conforme estabelecido na literatura observada.

Por fim, a análise dos resultados concentra-se na interpretação dos padrões descobertos, identificando variáveis mais influentes, tendências relevantes e possíveis perfis de risco. A interpretação busca estabelecer conexões entre os achados e ações institucionais potencialmente aplicáveis, em consonância com os objetivos da pesquisa e com a tendência de aplicação prática observada em estudos contemporâneos da área.

5. Aspectos Éticos do Uso da IA

O uso de técnicas de Inteligência Artificial e Mineração de Dados em contextos educacionais envolve uma série de considerações éticas relacionadas à privacidade, segurança e uso responsável das informações. Neste projeto, optou-se pela utilização de uma base de dados sintética, o que elimina riscos associados à exposição de dados pessoais e garante conformidade com princípios de proteção de dados.

Mesmo em ambientes simulados, é importante considerar possíveis vieses presentes nos dados ou introduzidos pelos algoritmos, que podem influenciar a

interpretação dos resultados. Modelos de análise podem reforçar padrões existentes ou gerar conclusões que, se aplicadas de forma inadequada, podem impactar negativamente decisões pedagógicas.

Além disso, destaca-se a responsabilidade no uso dos resultados gerados pelas técnicas de mineração de dados. As informações obtidas devem ser utilizadas como suporte à tomada de decisão, e não como substituição do julgamento humano.

6. Descrição do Dataset

O dataset selecionado contém dez milhões de registros de desempenho de alunos gerados sinteticamente, os quais foram projetados para simular dados educacionais reais de estudantes do ensino médio. Os dados incluem recursos detalhados, como: dados demográficos, socioeconômicos, acadêmicos, comportamentais e de contexto escolar para cada aluno. O processo de preparação dos dados foi simplificado em função das características da base sintética utilizada, que já se encontrava completa, sem valores ausentes ou inconsistências relevantes. Dessa forma, não foi necessário realizar etapas de imputação ou tratamento de dados faltantes.

Ainda assim, foram realizadas transformações com o objetivo de adequar os dados às técnicas analíticas empregadas. Variáveis numéricas contínuas, como notas, foram discretizadas por meio de arredondamento, facilitando sua interpretação e utilização em algoritmos baseados em regras de associação.

Adicionalmente, todos os atributos categóricos foram convertidos para formato binário por meio da técnica de one-hot encoding, permitindo sua utilização em modelos de mineração de dados e aprendizado de máquina.

7. Resultados Obtidos

A aplicação dos algoritmos de mineração de regras de associação permitiu a geração de conjuntos de regras por meio das três abordagens propostas: Apriori, Eclat e FP-Growth. Em todos os casos, foi possível executar os algoritmos sobre a base de dados previamente tratada e obter regras válidas a partir dos parâmetros de suporte, confiança e lift definidos ao longo dos experimentos.

Para fins de padronização metodológica e viabilidade, as regras mineradas foram restritas a combinações entre dois atributos por vez, o que possibilitou analisar de forma mais controlada as relações diretas entre pares de variáveis acadêmicas, sociais e comportamentais presentes na base. A variação dos parâmetros e dos tamanhos de amostras também evidenciou diferenças no comportamento dos algoritmos quanto à quantidade de regras geradas e à sensibilidade em relação à densidade dos dados.

Além da geração das regras, foram realizadas experimentações quanto à forma de disposição visual dos resultados, utilizando o gráfico D Chord como recurso para representar as conexões entre os itens que compõem as regras descobertas, facilitando a interpretação inicial dos padrões identificados.

8. Conclusão

Os resultados obtidos foram satisfatórios no que diz respeito à execução metodológica, à geração efetiva das regras e à comparação entre os algoritmos. Foi possível comprovar a viabilidade técnica da aplicação dessas abordagens, bem como observar diferenças práticas entre cada algoritmo utilizado.

Entretanto, embora os resultados tenham sido consistentes do ponto de vista técnico, ainda não se pode afirmar que o objetivo final do trabalho foi plenamente alcançado. A intenção futura é avançar na interpretação das regras mineradas e consolidar a defesa de que esses padrões poderão de fato servir como apoio à tomada de decisão no contexto pedagógico, contribuindo para propostas de intervenção educacional baseadas em dados.

9. Apresentação

A apresentação do projeto pode ser assistida por meio do vídeo disponível no link: <https://youtu.be/B2Qfy8MsxF8>

10. Referências bibliográficas

ALAVALA, H. R.; REDDY, V. K.; REDDY, V. C.; PARAMASIVAM, C.; RAMESH, T. K. **Educational data mining for predicting academic outcomes using ensemble techniques**. IEEE, 2025. Disponível em: <https://ieeexplore.ieee.org/document/10961471>.

ALGHAMDI, A. **Predicting student academic performance using machine learning algorithms based on online behavior data**. ACM, 2023. Disponível em: <https://doi.org/10.1145/3628797.3628882>.

ATTIYA, W. M.; SHAMS, M. B. **Predicting student retention in higher education using data mining techniques: a literature review**. IEEE, 2023. Disponível em: <https://ieeexplore.ieee.org/document/10051056>.

BHAGYA, A.; SRIPRIYA, P. **Predictive analysis in academic: an insight to challenges and techniques**. IEEE, 2022. Disponível em: <https://ieeexplore.ieee.org/document/9753869>.

BREZACK, N.; LEE, M.; COLLINS, K.; CHAN, W.; FENG, M. **Uncovering student profiles with problem solving and effort data from a tutoring system: insights from hierarchical cluster heatmap and latent profile analyses**. ACM, 2025. Disponível em: <https://doi.org/10.1145/3698205.3733951>.

CHEN, J.; ZHOU, X.; YAO, J.; TANG, S.-K. **Application of machine learning in higher education to predict students' performance, learning engagement and self-efficacy: a systematic literature review**. Asian Education and Development Studies, 2025. Disponível em: <https://doi.org/10.1108/AEDS-08-2024-0166>.

FENG, G.; FAN, M.; AO, C. **Exploration and visualization of learning behavior patterns from the perspective of educational process mining**. IEEE, 2022. Disponível em: <https://ieeexplore.ieee.org/document/9798836>.

KHAN, M.; NAZ, S.; KHAN, Y.; ZAFAR, M.; KHAN, M.; PAU, G. **Utilizing machine learning models to predict student performance from LMS activity logs**. IEEE, 2023. Disponível em: <https://ieeexplore.ieee.org/document/10216987>.

LAM, P. X.; MAI, P. Q. H.; NGUYEN, Q. H.; PHAM, T.; NGUYEN, T. H. H.; NGUYEN, T. H. **Enhancing educational evaluation through predictive student assessment modeling**. Computers and Education: Artificial Intelligence, 2024. Disponível em: <https://doi.org/10.1016/j.caeai.2024.100244>.

LI, W. **Improvements to the Apriori algorithm and its application in educational decision-making systems**. ACM, 2025. Disponível em: <https://doi.org/10.1145/3728725.3728784>.

MANIYAN, S.; GHOUSSI, R.; HAERI, A. **Data mining-based decision support system for educational decision makers: extracting rules to enhance academic efficiency**. Computers and Education: Artificial Intelligence, 2024. Disponível em: <https://doi.org/10.1016/j.caeai.2024.100242>.

RAHMAN, M. M.; WATANOBÉ, Y.; MATSUMOTO, T.; KIRAN, R. U.; NAKAMURA, K. **Educational data mining to support programming learning using problem-solving data**. IEEE, 2022. Disponível em: <https://ieeexplore.ieee.org/document/9729752>.

SAFOUR, H.; ESSGAER, M.; ALSHAREEF, A. **Unraveling academic failure: examining the influence of course correlations on student performance through association rules algorithms**. IEEE, 2024. Disponível em: <https://ieeexplore.ieee.org/document/10927837>.

WANG, J. **Education decision support system based on big data analysis: algorithm framework integrating machine learning and complex network theory**. ACM, 2024. Disponível em: <https://doi.org/10.1145/3691720.3691773>.

ZHOU, D.; ZHANG, X.; LIU, M.; YANG, Y.; YU, J.; YU, Y. **Analysis of the relationship between fine-grained daily spatial and temporal activity frequency and academic performance**. IEEE, 2021. Disponível em: <https://ieeexplore.ieee.org/document/9678802>.